


CONCIERGE

CONECTATEL:

ASSISTENTE INTELIGENTE COM RAG, BEDROCK, ESCALONAMENTO E
AUDITORIA

SQUAD 1

Ana Lícia Ferreira Soares
Gabriel Ferreira Oliveira
Kleidson Matos da Rocha
Pedro Henrique Oliveira Nascimento
Vinícius Nunes de Andrade



O PROBLEMA, A SOLUÇÃO E NOSSA JORNADA

Problema

- Atendimentos com diferentes níveis de complexidade.
- Risco de respostas sem evidência ou baseadas em políticas desatualizadas.
- Casos sensíveis precisam chegar ao humano com contexto.
- Necessidade de rastreabilidade do atendimento.

Nossa solução:

Pergunta

Concierge

ANSWER | NO_ANSWER | ESCALATE



SUMÁRIO

- Pipeline e análise dos dados
- Corpus, Metadados e RAG
- Concierge / Bedrock
- Triagem, Escalonamento e Handoff
- Integração, Auditoria e Qualidade
- Demonstração Funcional
- Decisões e Trade-offs
- Riscos e próximos passos



PIPELINE E ANÁLISE DOS DADOS

Tratamento

- Remoção de duplicidades.
- Padronização textual e booleana.
- Tratamento de nulos e outliers.
- Sem imputação artificial de CSAT/duração.



16,25%

PORTABILIDADE — MAIOR VOLUME

50%

FCR COBERTURA

58,14%

FCR TÉCNICO

66,67%

“SEM SINAL” — ESCALONAMENTO

63,64%

“SINAL INSTÁVEL”

Decisão gerada pelos dados

- Segurança e escalonamento para cenários com baixa capacidade de resolução automática.

A análise também preservou a anomalia do canal Loja Física, que apresentava apenas 29,17% de **encaminhado_humano**, em vez de modificar artificialmente o dado sintético.

CORPUS, METADADOS E RAG

01

CORPUS

- 12 documentos Markdown.
- FAQs, planos, políticas e procedimentos.

02

CHUNKING

- Estrutural por títulos Markdown.
- **CHUNK_SIZE** = 1000
- **OVERLAP** = 150
- 54 chunks
- ~341 caracteres em média.

03

EMBEDDINGS E BUSCA

- Amazon Titan Text Embeddings V2.
- Vetores de 1024 dimensões.
- FAISS **IndexFlatIP**.
- Busca exata.

04

GUARDRAIL DOCUMENTAL

Documento **revogado** é removido antes da similaridade.

05

VALIDAÇÃO

- Política vigente de reembolso: **90 dias**.
- Score aproximado: **0,8015**.
- **8/8 testes aprovados**.

Comparação de modelos

Modelo	NO_ANSWER	Latência Média	Custo / 3 testes
Mistral Large 3	Sim	494 ms	US\$ 0,00109
Nova Pro	Parcial	455 ms	~US\$ 0,00163
Claude Haiku 4.5	Sim	832 ms	~US\$ 0,00318

Escolha: Mistral Large 3

CONCIERGE /
BEDROCK

Threshold

ABSTENTION_THRESHOLD = 0.30

- 25/26 ANSWER liberados.
- 5/5 NO_ANSWER bloqueados.
- ≈ 96,8% de acerto.

Segurança

score < 0.30 → early exit → LLM NÃO é chamado

- Grounding obrigatório.
- Fontes determinísticas.
- Sem fonte suficiente → NO_ANSWER.

A Frente 3 comparou os três modelos sob o mesmo contexto, system prompt e parâmetros e escolheu o Mistral Large 3 pelo equilíbrio entre qualidade, aderência à abstenção, latência e custo.

O threshold 0,30 foi calibrado utilizando 26 casos ANSWER e 5 NO_ANSWER, atingindo aproximadamente 96,8% no conjunto avaliado.

Triagem determinística**Casos sensíveis**

- Fraude.
- Contestação de alto valor.
- Multa de fidelidade.
- Alteração de titularidade/falecimento.
- Anatel / Procon / ação judicial.
- Conduta abusiva / assédio.
- Visita técnica.

**Por que determinístico?**

Regras críticas de negócio não dependem exclusivamente da interpretação do LLM.

**Handoff****10 campos estruturados**, incluindo:

- protocolo;
- data/hora;
- canal;
- categoria;
- resumo do caso;
- histórico;
- produto/serviço;
- documento consultado;
- urgência;
- contato para retorno.

TRIAGEM, ESCALONAMENTO E HANDOFF

Objetivo


- O cliente não precisa repetir todo o contexto para o atendente humano.


As regras e o payload estruturado estão descritos como mecanismos determinísticos justamente para assegurar aderência às políticas organizacionais.

INTEGRAÇÃO, AUDITORIA E QUALIDADE

1. Contrato de decisão	2. Rastreabilidade	3. Auditoria
ANSWER → resposta + ≥ 1 citação vigente NO_ANSWER → sem resposta inventada e sem citação ESCALATE → handoff completo	trace_id único por interação Permite reconstruir o atendimento Rastreabilidade ponta a ponta	Pergunta e resposta Decisão + citações / handoff Score + duração + guardrail Versões dos componentes

INTEGRAÇÃO, AUDITORIA E QUALIDADE





DEMONSTRAÇÃO FUNCIONAL



DECISÕES E TRADE-OFFS

Escolha	Benefício	O que sacrificamos
Preservar anomalias dos logs	Fidelidade à fonte	Dados menos “bonitos”
FAISS exato	Simplicidade e precisão	Menor ganho de escala
Filtro de vigência antes da busca	Segurança documental	Menos candidatos
Threshold 0,30	Menos alucinação	Perda de recall
Early exit	Menor custo e latência	Menos tentativas do LLM
Triagem determinística	Previsibilidade	Menos flexibilidade
Handoff estruturado	Continuidade	Maior rigor de contrato
API com interruptor SSM	Controle de custo/exposição	Não fica sempre disponível

RISCOS E PRÓXIMOS PASSOS

RISCOS CONHECIDOS

- Dependência de S3 e Bedrock.
- Credenciais temporárias expiram.
- Deploy depende de SAM, Docker e IAM.
- Threshold precisa ser recalibrado se o corpus crescer.
- Dataset sintético possui anomalias conhecidas. Ex.: comportamento de Loja Física.
- Métricas da interface são locais à sessão.

PRÓXIMOS PASSOS

- Expandir Golden Set.
- Recalibrar threshold.
- Ampliar observabilidade.
- Automatizar CI/CD.
- Testar com dados reais.



AGRADECEMOS A ATENÇÃO



GITHUB

[https://github.com/gabriell159/
Rag_conectatel](https://github.com/gabriell159/Rag_conectatel)
